



HTW Chur



Hochschule für Technik und Wirtschaft
University of Applied Sciences

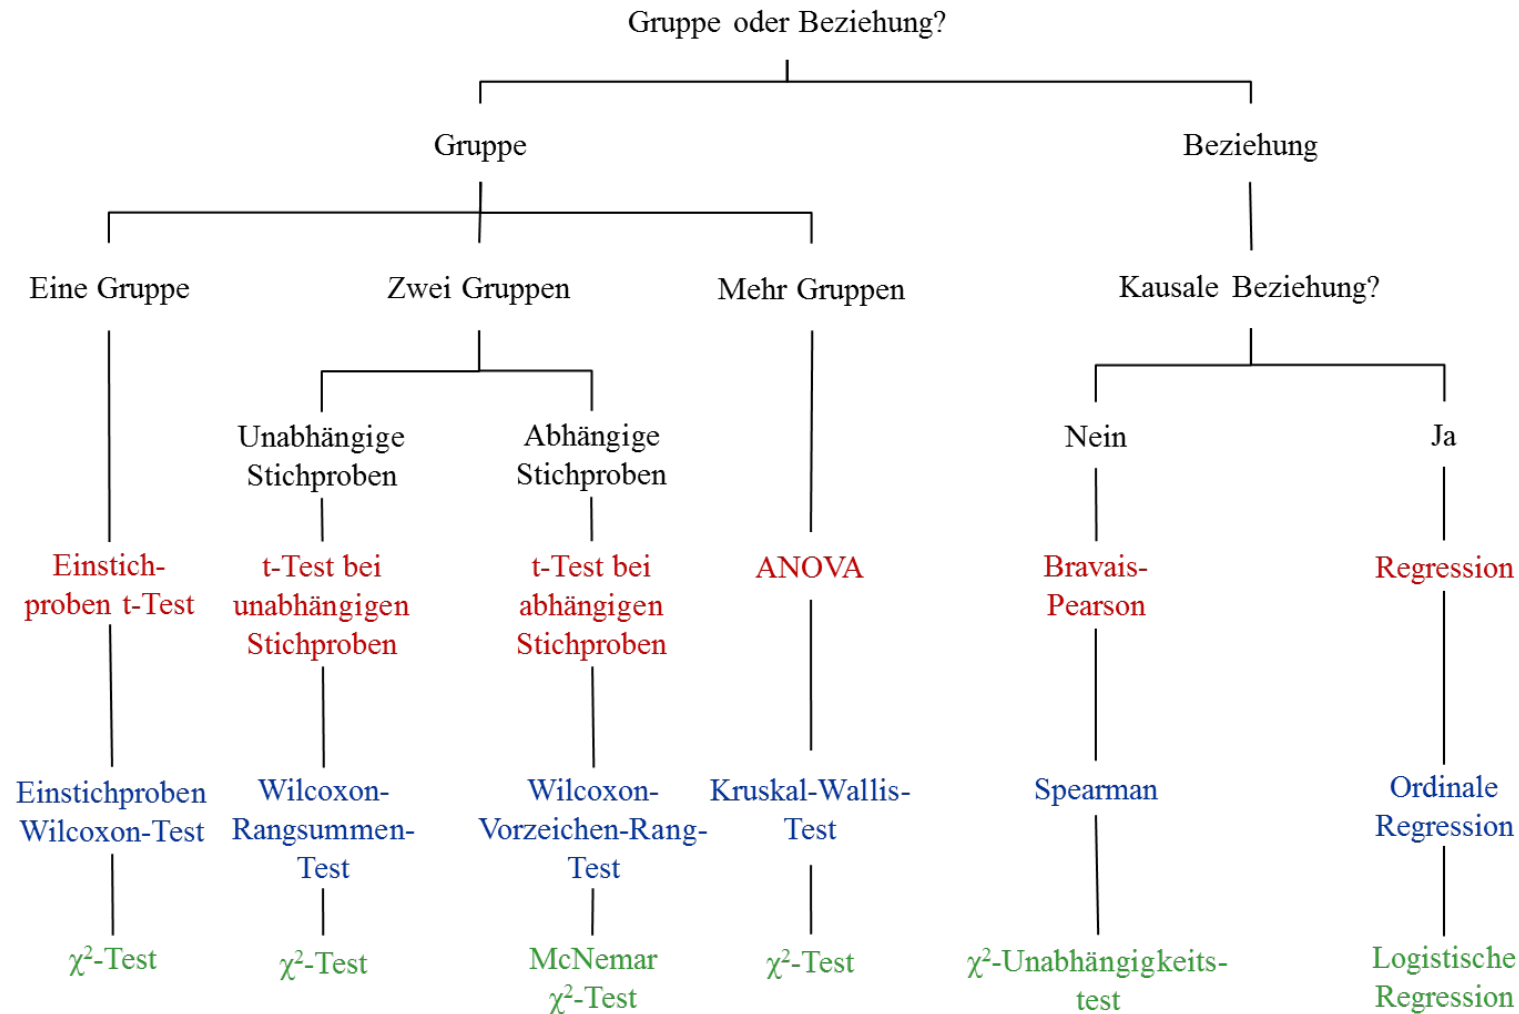
Parametrische und nicht-parametrische Testverfahren

Quantitative Forschungsmethoden

Prof. Dr. Franz Kronthaler

- verstehen des Unterschieds zwischen parametrischen und nicht-parametrischen Testverfahren
- wissen wann parametrische oder nicht-parametrische Testverfahren sachgemäss sind
- wissen wie der t-Test für unabhängige Stichproben berechnet und interpretiert wird
- wissen wie der Wilcoxon-Rangsummen-Test berechnet und interpretiert wird
- wissen wie der t-Test für abhängige Stichproben berechnet und interpretiert wird
- wissen wie der Wilcoxon-Vorzeichen-Rang-Test berechnet und interpretiert wird
- verstehen wie das angemessene Testverfahren basierend auf der Fragestellung, der Daten und der Stichprobengrösse auszuwählen ist

Einleitung



Variable(n) von Interesse sind: - metrisch und normal verteilt
- ordinal oder metrisch und nicht-normal verteilt
- nominal

Parametrische und nicht-parametrische Testverfahren

- parametrische Testverfahren erfordern Kenntnis über die Verteilung der Testdaten, typischerweise wird der Ausdruck für Tests verwendet, die metrisch und normalverteilte Daten voraussetzen
- Beispiele für parametrische Testverfahren sind
 - der t-Test bei unabhängigen Stichproben
 - der t-Test bei abhängigen Stichproben
 - die ANOVA
- nicht-parametrische Testverfahren sind Testverfahren, die keine spezifische Verteilung der Daten voraussetzen
- nicht-parametrische Testverfahren werden auch als verteilungsfreie Tests bezeichnet
- Beispiele für nicht-parametrische Testverfahren sind
 - die χ^2 -Tests
 - der Wilcoxon-Rangsummen-Test
 - der Wilcoxon-Vorzeichen-Rang-Test
 - der Kruskal-Wallis-Test

Parametrische und nicht-parametrische Testverfahren

- Gründe für die Anwendung eines parametrischen Testverfahrens
 - die Testvariable ist metrisch und normalverteilt
 - die Testvariable ist metrisch und nicht-normalverteilt, aber die Stichprobengrösse ist gross (parametrische Testverfahren sind bei grosser Stichprobe relativ robust)
- Gründe für die Anwendung eines nicht-parametrischen Testverfahrens
 - die Testvariable ist metrisch, aber nicht-normalverteilt
 - die Testvariable ist ordinal
 - die Testvariable ist nominal
 - der Sachverhalt von Interesse wird am Besten durch den Median repräsentiert (nicht durch den arithmetischen Mittelwert)
 - die Stichprobengrösse ist klein (bei kleiner Stichprobengrösse ist es schwierig zu entscheiden, ob die Testvariable normalverteilt ist)
 - Ausreisser (Ausreisser können das Ergebnis eines parametrischen Tests stark beeinflussen)

t-Test bei unabhängigen Stichproben

t-Test bei unabhängigen Stichproben

- der t-Test bei unabhängigen Stichproben ist ein parametrischer Test
- der t-Test bei unabhängigen Stichproben vergleicht die Mittelwerte zwei Stichproben und testet, ob es einen signifikanten Unterschied zwischen den Gruppen in der Grundgesamtheit gibt
- die Testvariable sollte metrisch und normalverteilt sein
- Wie ist der Test durchzuführen?
 - Schritt 1: Formuliere die Forschungsfrage, H_0 , H_A und α
 - Schritt 2: Berechne die Teststatistik
 - Schritt 3: Prüfe auf Signifikanz

t-Test bei unabhängigen Stichproben

- Beispiel:

- Schritt 1:

- Gibt es einen Unterschied im Lernerfolg zwischen Klasse A und Klasse B?
 - $H_0: \mu_A - \mu_B = 0$
 - $H_A: \mu_A - \mu_B \neq 0$
 - $\alpha = 0.05$

- Schritt 2:

- um die Hypothese zu prüfen werden Stichprobendaten für die beiden Klassen erhoben:

	Punkte in der Prüfung (max. 60)									\bar{x}	s
Klasse A	53	49	60	34	45	49	56	44	57	49.67	8.00
Klasse B	45	54	57	25	50	45	42	40	39	44.11	9.44

- Es gibt einen Unterschied in der Stichprobe, aber ist dieser Unterschied signifikant?

t-Test bei unabhängigen Stichproben

- die Teststatistik ist die Differenz der Mittelwerte geteilt durch die Standardabweichung der Stichprobenverteilung

$$t = \frac{\bar{x}_A - \bar{x}_B}{\sigma_{\bar{x}_A, \bar{x}_B}} = 1.35$$

mit

$$\sigma_{\bar{x}_A, \bar{x}_B} = \sqrt{\left[\frac{(n_A - 1)s_A^2 + (n_B - 1)s_B^2}{n_A + n_B - 2} \right] \left[\frac{n_A + n_B}{n_A \times n_B} \right]} = 4.12$$

– Schritt 3

- vergleiche den Testwert mit dem kritischen Wert der t-Verteilung, $Fg = n_A + n_B - 2 = 16$
- der kritische Wert ist ± 2.120
- H_0 wird nicht verworfen, es gibt keinen Unterschied im Lernerfolg zwischen den beiden Gruppen

t-Test bei unabhängigen Stichproben

- Anmerkungen
 - soweit haben wir gleiche Varianz für beide Gruppen angenommen
 - die Teststatistik ist leicht anders, wenn ungleiche Varianzen vorliegen
 - d. h. wir müssen auf Gleichheit der Varianzen prüfen
 - wir können uns die Varianzen der Stichproben ansehen $var = s^2$
 - ❖ $var_A = s_A^2 = 8.00^2 = 64.00$
 - ❖ $var_B = s_B^2 = 9.44^2 = 89.11$
 - wir können mit Hilfe des Tests von Levene auf gleiche Varianzen testen
 - ❖ H_0 : Die Varianzen in beiden Gruppen sind gleich.
 - ❖ H_A : Die Varianzen in beiden Gruppen sind nicht gleich.
 - ❖ $\alpha = 0.05$

Beispiel t-Test bei unabhängigen Stichproben

- im Folgenden führen wir den t-Test bei unabhängigen Stichproben mit Hilfe des R Commanders durch
 - der Datensatz ist growth.Rdata
 - der Datensatz ist simuliert und stammt aus dem Lehrbuch Kronthaler 2016
 - der Datensatz enthält Informationen zu neu gegründeten Unternehmen und den Gründern

lade den Datensatz "growth.Rdata"

Beispiel t-Test bei unabhängigen Stichproben

- Schritt 1:
 - Gibt es einen Unterschied im Gründungsalter zwischen Gründerinnen und Gründern?
 - $H_0: \mu_M - \mu_F = 0$
 - $H_A: \mu_M - \mu_F \neq 0$
 - $\alpha = 0.05$
 - Schritt 2:
 - bevor wir den Test durchführen sollten wir die Daten vorbereiten und die deskriptive Statistiken ansehen
 - ❖ teile R mit, dass die Variable sex eine Faktorvariable ist
- # nutze die Benutzeroberfläche des R Commanders oder den folgenden Befehl
- ```
growth$f_sex<-as.factor(growth$sex)
```

## Beispiel t-Test bei unabhängigen Stichproben

---

- ❖ prüfe die Testvariable auf Normalverteilung

# nutze die Benutzeroberfläche des R Commanders oder die folgenden Befehle

```
attach(growth)
```

```
hist(age, scale="frequency", breaks="Sturges", col="deeppink")
```

```
qqPlot(age, dist="norm", id.method="y", id.n=2, labels=rownames(growth))
```

```
shapiro.test(age)
```

```
detach(growth)
```

## Beispiel t-Test bei unabhängigen Stichproben

---

- ❖ prüfe ob die Gruppen gleiche Varianzen haben

# nutze die Benutzeroberfläche des R Commanders oder die folgenden Befehle

```
numSummary(growth[, "age"], groups=growth$f_sex, statistics=c("mean",
"sd"), quantiles=c(0,.25,.5,.75,1))
```

```
leveneTest(age ~ f_sex, data=growth, center="mean")
```

- ❖ betrachte die deskriptiven Statistiken, insbesondere den arithmetischen Mittelwert und die Standardabweichung

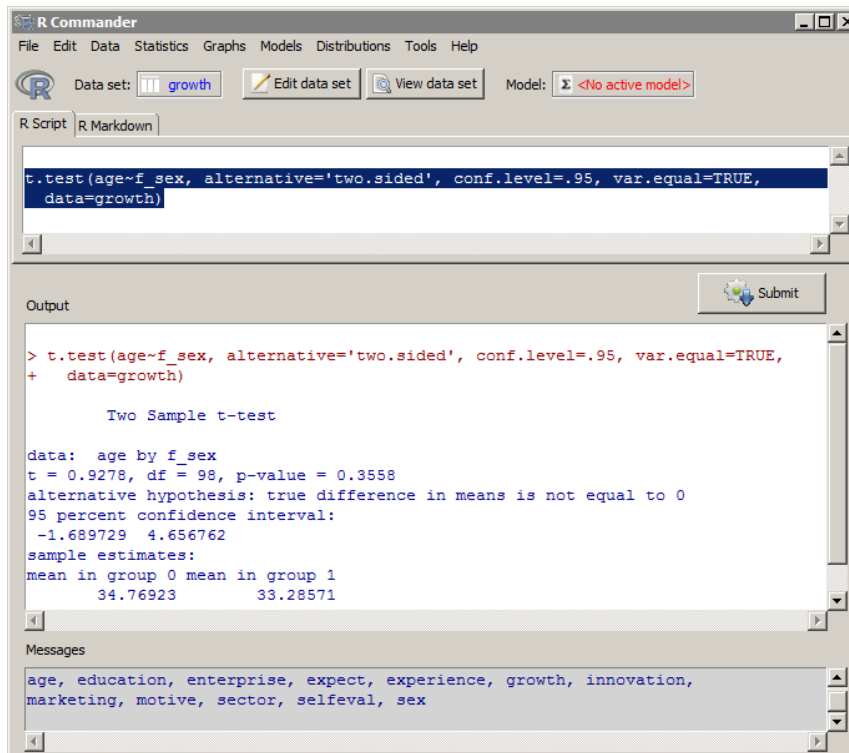
- führe den Test durch

# nutze die Benutzeroberfläche des R Commanders oder den folgenden Befehl

```
t.test(age~f_sex, alternative='two.sided', conf.level=.95, var.equal=TRUE,
data=growth)
```

# Beispiel t-Test bei unabhängigen Stichproben

## – Schritt 3:



The screenshot shows the R Commander window. The 'Data set' is 'growth'. The 'Model' is '<No active model>'. The 'R Script' tab is active, showing the command: `t.test(age~f_sex, alternative='two.sided', conf.level=.95, var.equal=TRUE, data=growth)`. The 'Output' tab is active, showing the results of the t-test.

```
> t.test(age~f_sex, alternative='two.sided', conf.level=.95, var.equal=TRUE,
+ data=growth)

Two Sample t-test

data: age by f_sex
t = 0.9278, df = 98, p-value = 0.3558
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -1.689729 4.656762
sample estimates:
mean in group 0 mean in group 1
 34.76923 33.28571
```

The 'Messages' tab is also active, showing the list of variables: age, education, enterprise, expect, experience, growth, innovation, marketing, motive, sector, selfeval, sex.

# Anwendungen

---

- Die Frage ist, ob neu gegründete Unternehmen des Dienstleistungssektors oder neu gegründete Unternehmen des Industriesektors höhere Umsatzwachstumsraten erzielen. Die folgenden Stichprobenwerte sind gegeben:

$$n_{ind} = 34, \bar{x}_{ind} = 6.35, sd_{ind} = 5.03$$

$$n_{ser} = 66, \bar{x}_{ser} = 7.49, sd_{ser} = 5.77$$

Teste zum 5% Signifikanzniveau. Berechne den Test von Hand.

- Nutze den Datensatz growth.Rdata. Teste mit Hilfe des R Commanders, ob Unternehmen des Dienstleistungssektors oder Unternehmen des Industriesektors höhere Wachstumsraten erzielen. Teste zum Signifikanzniveau von 10%.



---

# Wilcoxon-Rangsummen-Test

# Wilcoxon-Rangsummen-Test

---

- der Wilcoxon-Rangsummen-Test (Wilcoxon–Mann–Whitney-Test) ist die nicht-parametrische Alternative zum t-Test bei unabhängigen Stichproben
- die Testvariable ist ordinal oder metrisch und nicht normalverteilt
- der Wilcoxon-Rangsummen-Test testet, ob die zwei Gruppen die selbe zentrale Tendenz haben
- Wie wird der Test durchgeführt?
  - Schritt 1: Formuliere die Forschungsfrage,  $H_0$ ,  $H_A$  und  $\alpha$
  - Schritt 2: Berechne die Teststatistik
  - Schritt 3: Prüfe auf Signifikanz

# Wilcoxon-Rangsummen-Test

- Beispiel:

- Schritt 1:

- Hat Klasse A bessere Noten als Klasse B?
    - $H_0: me_A - me_B \leq 0$
    - $H_A: me_A - me_B > 0$
    - $\alpha = 0.05$

- Schritt 2:

- um die Hypothese zu prüfen wird eine Stichprobe für beide Klassen gezogen und es werden die Noten erhoben:

|          | Noten |     |     |     |     |     |     |     |     |     | Median |
|----------|-------|-----|-----|-----|-----|-----|-----|-----|-----|-----|--------|
| Klasse A | 5.5   | 4.3 | 5.1 | 3.6 | 5.8 | 2.5 | 3.9 | 5.9 | 6.0 | 4.4 | 4.75   |
| Klasse B | 3.7   | 5.7 | 4.8 | 4.6 | 3.5 | 4.0 | 5.6 | 4.1 | 4.5 | 5.3 | 4.50   |

- Es gibt einen Unterschied in der Stichprobe, aber ist der Unterschied signifikant?

# Wilcoxon-Rangsummen-Test

- um die Teststatistik zu berechnen sind zuerst die Rangwerte für beide Stichproben zu vergeben

|         |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |
|---------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| Noten   | 2.5 | 3.5 | 3.6 | 3.7 | 3.9 | 4.0 | 4.1 | 4.3 | 4.4 | 4.5 | 4.6 | 4.8 | 5.1 | 5.3 | 5.5 | 5.6 | 5.7 | 5.8 | 5.9 | 6.0 |
| Klassen | A   | B   | A   | B   | A   | B   | B   | A   | A   | B   | B   | B   | A   | B   | A   | B   | B   | A   | A   | A   |
|         | 1   | 2   | 3   | 4   | 5   | 6   | 7   | 8   | 9   | 10  | 11  | 12  | 13  | 14  | 15  | 16  | 17  | 18  | 19  | 20  |

- wenn die zwei Klassen identische Verteilungen aufweisen, würden wir dieselbe Rangsumme erwarten
  - ❖  $W_A = 1 + 3 + 5 + 8 + 9 + 13 + 15 + 18 + 19 + 20 = 111$
  - ❖  $W_B = 2 + 4 + 6 + 7 + 10 + 11 + 12 + 14 + 16 + 17 = 99$
- der Wilcoxon-Rangsummen-Test vergleicht nicht die zwei Rangsummen, sondern eine der Rangsummen mit der durchschnittlichen Rangsumme
- in diesem Fall ist Rangsumme  $W$  der ersten Stichprobe die Teststatistik

# Wilcoxon-Rangsummen-Test

---

- $W$  hat den Mittelwert

$$\mu_W = \frac{n_1(N + 1)}{2}$$

und die Standardabweichung

$$\sigma_W = \sqrt{\frac{n_1 n_2 (N + 1)}{12}}$$

- der Wilcoxon-Rangsummen-Test verwirft die Hypothese, dass die zwei Gruppen identische Verteilungen haben, wenn die Rangsumme deutlich vom Mittelwert abweicht

# Wilcoxon-Rangsummen-Test

- in unserem Beispiel haben wir die folgenden Zahlen
  - ❖  $n_A = 10, n_B = 10$
  - ❖  $N = n_A + n_B = 20$
  - ❖  $\mu_W = \frac{n_A(N+1)}{2} = \frac{10(20+1)}{2} = 105$
  - ❖  $\sigma_W = \sqrt{\frac{n_1 n_2 (N+1)}{12}} = \sqrt{\frac{10 \cdot 10 (20+1)}{12}} = \sqrt{175} = 13.23$
  - ❖  $W_A = 111$
- $W_A$  weicht von  $\mu_W$  ab, ist der Unterschied aber gross genug?
  - ❖ die Differenz ist 6
  - ❖ es ist weniger als eine halbe Standardabweichung  $6/13.23 = 0.45$
  - ❖ wir erwarten, dass der Unterschied nicht gross genug ist um  $H_0$  zu verwerfen

# Wilcoxon-Rangsummen-Test

– Schritt 3:

- um zu entscheiden brauchen wir zusätzliche Informationen über die Testverteilung
- die Testverteilung hängt von der Stichprobengrösse  $n_1$  und  $n_2$  ab
- wenn  $n_1 \geq 10$  und  $n_2 \geq 10$  ist die Teststatistik  $W$  annähernd normalverteilt und wir können die Standardnormalverteilung nutzen
- wenn nicht, nutzen wir die Wilcoxon Rangsummen-Verteilungstabelle (suche im Internet nach der Tabelle)
- in unserem Fall ist die standardisierte Rangsummenstatistik

$$z = \frac{W - \mu_W}{\sigma_W} = \frac{111 - 105}{13.23} = 0.45$$

- ❖  $z = 0.45$  hat eine Wahrscheinlichkeit von 32.64% (vergleiche die Standardnormalverteilungstabelle)
- ❖ der Wert ist deutlich über dem spezifizierten Signifikanzniveau von 5%
- ❖ wir verwerfen  $H_0$  nicht

## Beispiel Wilcoxon-Rangsummen-Test

---

- um den Wilcoxon-Rangsummen-Test durchzuführen nutzen wir den folgenden Beispieldatensatz
    - der Datensatz ist growth.Rdata
    - der Datensatz ist simuliert und stammt aus dem Lehrbuch Kronthaler 2016
    - der Datensatz enthält Informationen zum
      - Geschlecht der Unternehmensgründer/innen
      - zur Selbstbewertung der Gründer hinsichtlich ihrer Berufserfahrung
- # lade den Datensatz "growth.Rdata"

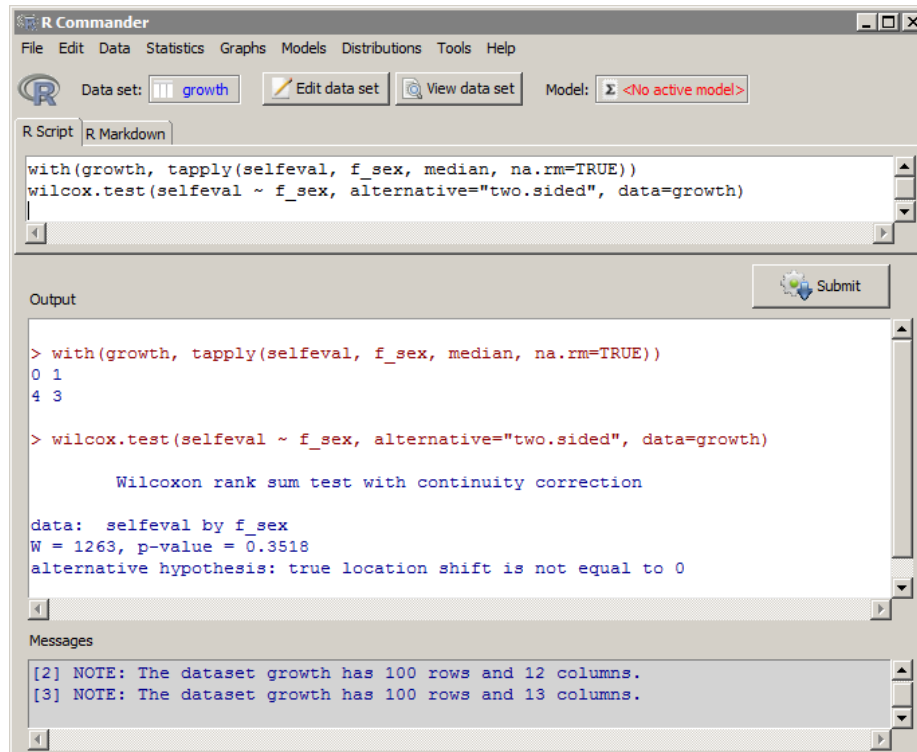


# Beispiel Wilcoxon-Rangsummen-Test

- Schritt 1:
  - Gibt es einen Unterschied in der Selbstbewertung zwischen Gründern und Gründerinnen?
  - $H_0: me_M - me_F = 0$
  - $H_A: me_M - me_F \neq 0$
  - $\alpha = 0.05$
- Schritt 2:
  - bevor wir den Test durchführen müssen wir die Daten vorbereiten
  - teile R mit, dass die Variable sex eine Faktorvariable ist
    - # nutze die Benutzeroberfläche des R Commanders oder den folgenden Befehl
    - `growth$f_sex<-as.factor(growth$sex)`
  - führe den Test durch
    - # nutze die Benutzeroberfläche des R Commanders oder die folgenden Befehle
    - `with(growth, tapply(selfeval, f_sex, median, na.rm=TRUE))`
    - `wilcox.test(selfeval ~ f_sex, alternative="two.sided", data=growth)`

# Beispiel Wilcoxon-Rangsummen-Test

## – Schritt 3:



The screenshot shows the R Commander window with the following components:

- Menu Bar:** File, Edit, Data, Statistics, Graphs, Models, Distributions, Tools, Help.
- Buttons:** Data set: `growth`, Edit data set, View data set, Model: `<No active model>`.
- R Script Tab:** Contains the following code:

```
with(growth, tapply(selfeval, f_sex, median, na.rm=TRUE))
wilcox.test(selfeval ~ f_sex, alternative="two.sided", data=growth)
```
- Output Tab:** Contains the following output:

```
> with(growth, tapply(selfeval, f_sex, median, na.rm=TRUE))
0 1
4 3

> wilcox.test(selfeval ~ f_sex, alternative="two.sided", data=growth)

 Wilcoxon rank sum test with continuity correction

data: selfeval by f_sex
W = 1263, p-value = 0.3518
alternative hypothesis: true location shift is not equal to 0
```
- Messages Tab:** Contains the following messages:

```
[2] NOTE: The dataset growth has 100 rows and 12 columns.
[3] NOTE: The dataset growth has 100 rows and 13 columns.
```

# Anwendungen

---

- Nutze den Datensatz growth.Rdata. Teste mit der Hilfe des R Commanders ob es einen Unterschied in der Ausbildung zwischen Gründern und Gründerinnen gibt.
- Nutze den Datensatz gssft.RData (Lehrbuch von Norusis 2008) um zu prüfen, ob es einen Unterschied in der Arbeitszeit (Variable hrs1) zwischen Männern und Frauen gibt (Variable sex).
  - Führe den t-Test bei unabhängigen Stichproben durch.
  - Führe den Wilcoxon-Rangsummen-Test durch.
  - Vergleiche die Ergebnisse.
  - Welchen Test ziehen Sie vor? Warum?



---

## **t-Test bei abhängigen Stichproben**

## t-Test bei abhängigen Stichproben

---

- der t-Test bei abhängigen Stichproben ist ein parametrisches Testverfahren
- der t-Test bei abhängigen Stichproben testet die Wirksamkeit einer Massnahme
- er vergleicht den Stichprobenmittelwert vor und nach einer Massnahme, z. B.
  - Beeinflusst das Trinken von Bier die Fahrfähigkeit von Personen?
  - Hat ein Medikament einen Einfluss auf den Gesundheitszustand von Personen?
  - Hat eine Werbemassnahme einen Einfluss auf das Image eines Produktes bei Personen?
- die Testvariable ist metrisch und normalverteilt
- Wie wird der Test durchgeführt?
  - Schritt 1: Formuliere die Forschungsfrage,  $H_0$ ,  $H_A$ , und  $\alpha$
  - Schritt 2: Kalkuliere die Teststatistik
  - Schritt 3: Prüfe auf Signifikanz

# t-Test bei abhängigen Stichproben

- Beispiel:
  - Schritt 1:
    - Hilft die Trainingsmassnahme die Produktivität zu erhöhen?
    - $H_0: \mu_{pre} - \mu_{post} \geq 0$
    - $H_A: \mu_{pre} - \mu_{post} < 0$
    - $\alpha = 0.1$
  - Schritt 2:
    - um die Hypothese zu prüfen wurde eine Stichprobe vor und nach der Trainingsmassnahme beobachtet

|          | produzierte Einheiten pro Stunde |     |     |     |     |     |     |     |     | $\bar{x}$ | $s$  |
|----------|----------------------------------|-----|-----|-----|-----|-----|-----|-----|-----|-----------|------|
| Arbeiter | 1                                | 2   | 3   | 4   | 5   | 6   | 7   | 8   | 9   |           |      |
| pre      | 160                              | 180 | 150 | 130 | 150 | 110 | 150 | 140 | 130 | 140.0     | 20.6 |
| ex post  | 180                              | 170 | 170 | 140 | 160 | 140 | 150 | 160 | 120 | 150.0     | 16.6 |

- Es gibt einen Unterschied, aber ist der Unterschied signifikant?

## t-Test bei abhängigen Stichproben

- die Teststatistik ist  $t = \frac{\sum d_i}{\sqrt{\frac{n \sum d_i^2 - (\sum d_i)^2}{n-1}}}$

$d_i$  ist die Differenz zwischen vor und nach der Massnahme

$n$  ist die Zahl der Paarbeobachtungen

| Arbeiter | pre | ex_post | di  | di <sup>2</sup> |
|----------|-----|---------|-----|-----------------|
| 1        | 120 | 140     | -20 | 400             |
| 2        | 180 | 170     | 10  | 100             |
| 3        | 150 | 170     | -20 | 400             |
| 4        | 130 | 140     | -10 | 100             |
| 5        | 150 | 160     | -10 | 100             |
| 6        | 110 | 140     | -30 | 900             |
| 7        | 150 | 150     | 0   | 0               |
| 8        | 140 | 160     | -20 | 400             |
| 9        | 130 | 120     | 10  | 100             |
| Summe    |     |         | -90 | 2500            |

- $t = \frac{\sum d_i}{\sqrt{\frac{n \sum d_i^2 - (\sum d_i)^2}{n-1}}} = \frac{-90}{\sqrt{\frac{9 \cdot 2500 - (-90)^2}{8}}} = \frac{-90}{42.43} = -2.12$

## t-Test bei abhängigen Stichproben

---

- Schritt 3:
  - vergleiche den Testwert mit dem kritischen Wert der t-Tabelle mit  $Fg = n - 1 = 9 - 1 = 8$
  - der kritische Wert ist  $-1.397$
  - $H_0$  wird verworfen, die Massnahme erhöht die Produktivität



## Beispiel t-Test bei abhängigen Stichproben

---

- um den t-Test bei abhängigen Stichproben mit dem R Commander durchzuführen nutzen wir den folgenden Beispieldatensatz
    - training.RData
    - der Datensatz ist simuliert
    - er enthält das eben diskutierte Beispiel
- # lade den Datensatz "training.Rdata"

## Beispiel t-Test bei abhängigen Stichproben

- Schritt 1:
  - Hilft die Trainingsmassnahme die Produktivität zu erhöhen?
  - $H_0: \mu_{pre} - \mu_{post} \geq 0$
  - $H_A: \mu_{pre} - \mu_{post} < 0$
  - $\alpha = 0.1$
- Schritt 2:
  - betrachte die deskriptiven Statistiken
    - # nutze die Benutzeroberfläche des R Commanders oder die folgenden Befehle
    - `attach(training)`
    - `mean(pre)`
    - `mean(ex_post)`
    - `sd(pre)`
    - `sd(ex_post)`
    - `detach(training)`

## Beispiel t-Test bei abhängigen Stichproben

---

- prüfe/ teste, ob die Testvariable normalverteilt ist

# nutze die Benutzeroberfläche des R Commanders oder die folgenden Befehle

```
attach(training)
```

```
hist(di, scale="frequency", breaks="Sturges", col="red")
```

```
qqPlot(di, dist="norm", id.method="y", id.n=2, labels=rownames(training))
```

```
shapiro.test(di)
```

```
detach(training)
```

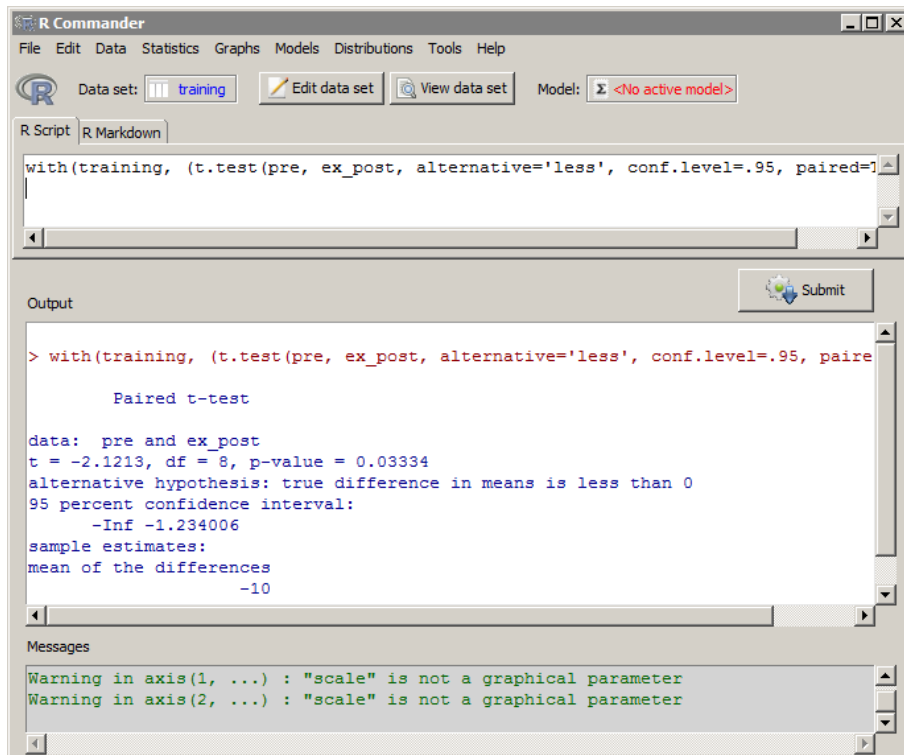
- führe den Test durch

# nutze die Benutzeroberfläche des R Commanders oder den folgenden Befehl

```
with(training, (t.test(pre, ex_post, alternative='less', conf.level=.95,
paired=TRUE)))
```

# Beispiel t-Test bei abhängigen Stichproben

## – Schritt 3:



The screenshot shows the R Commander window. The 'Data set' is 'training'. The 'Model' is '<No active model>'. The 'R Script' tab is active, showing the command: `with(training, (t.test(pre, ex_post, alternative='less', conf.level=.95, paired=`. The 'Output' tab shows the results of the paired t-test: `> with(training, (t.test(pre, ex_post, alternative='less', conf.level=.95, paire`  
`Paired t-test`  
`data: pre and ex_post`  
`t = -2.1213, df = 8, p-value = 0.03334`  
`alternative hypothesis: true difference in means is less than 0`  
`95 percent confidence interval:`  
`-Inf -1.234006`  
`sample estimates:`  
`mean of the differences`  
`-10`. The 'Messages' tab shows two warnings: `Warning in axis(1, ...) : "scale" is not a graphical parameter` and `Warning in axis(2, ...) : "scale" is not a graphical parameter`.

## Anwendungen

- Wir sind daran interessiert, ob ein Schulungsprogramm für Buchhaltung die Effizienz bei der Durchführung der Buchhaltung erhöht. Wir beobachten 15 Teilnehmer und erhalten die folgenden Daten:

| Teilnehmer | pre | ex post | $d_i$ | $d_i^2$ |
|------------|-----|---------|-------|---------|
| 1          | 17  | 19      | -2    | 4       |
| 2          | 9   | 7       | 2     | 4       |
| 3          | 21  | 15      | 6     | 36      |
| 4          | 30  | 25      | 5     | 25      |
| 5          | 29  | 31      | -2    | 4       |
| 6          | 33  | 33      | 0     | 0       |
| 7          | 5   | 4       | 1     | 1       |
| 8          | 18  | 10      | 8     | 64      |
| 9          | 28  | 30      | -2    | 4       |
| 10         | 11  | 8       | 3     | 9       |
| 11         | 14  | 14      | 0     | 0       |
| 12         | 6   | 5       | 1     | 1       |
| 13         | 5   | 7       | -2    | 4       |
| 14         | 12  | 11      | 1     | 1       |
| 15         | 13  | 15      | -2    | 4       |

Teste zum 10%-Signifikanzniveau. Kalkuliere die Werte von Hand.

## Anwendungen

---

- Wir sind daran interessiert, ob Energy-Drinks die Leistung von Athleten steigert. Nutze den simulierten Datensatz `energy.Rdata`. Teste mit Hilfe des R Commanders zum 1%-Signifikanzniveau.



---

## Wilcoxon-Vorzeichen-Rang-Test

# Wilcoxon-Vorzeichen-Rang-Test

---

- der Wilcoxon-Vorzeichen-Rang-Test ist die nicht-parametrische Alternative zum t-Test bei abhängigen Stichproben
- die Testvariable ist ordinal oder metrisch, aber nicht normalverteilt
- der Wilcoxon-Vorzeichen-Rang-Test testet, ob die zentrale Tendenz zweier gepaarter Stichproben gleich ist
- Wie wird der Test durchgeführt?
  - Schritt 1: Formuliere die Forschungsfrage,  $H_0$ ,  $H_A$  und  $\alpha$
  - Schritt 2: Kalkuliere die Teststatistik
  - Schritt 3: Prüfe auf Signifikanz



# Wilcoxon-Vorzeichen-Rang-Test

- Beispiel:
  - Irgendwo im Norden von Europa gibt es eine Schule, welche Schülern und Schülerinnen die Möglichkeit gibt, während der Schulpausen mit Fitnessgeräten zu trainieren. Die Schule macht dies, um das Übergewicht bei Kindern zu reduzieren.
  - Schritt 1:
    - Reduzieren aktive Schulpausen mit Fitnessgeräten das Gewicht von Kindern?
    - $H_0: me_{pre} - me_{post} \leq 0$
    - $H_A: me_{pre} - me_{post} > 0$
    - $\alpha = 0.05$
  - Schritt 2:
    - um die Hypothese zu testen führen wir ein Experiment durch und beobachten die Kinder vor und einige Zeit nach der Einführung aktiver Schulpausen

|         | Gewicht |      |      |      |      |      |      |      |      | $\bar{x}$ | s    |
|---------|---------|------|------|------|------|------|------|------|------|-----------|------|
| Kinder  | 1       | 2    | 3    | 4    | 5    | 6    | 7    | 8    | 9    |           |      |
| pre     | 30.0    | 35.0 | 33.0 | 28.0 | 60.0 | 37.0 | 32.0 | 29.0 | 31.0 | 35.0      | 9.8  |
| ex post | 27.0    | 30.0 | 34.0 | 28.0 | 62.0 | 33.0 | 28.5 | 28.5 | 26.5 | 33.1      | 11.2 |

# Wilcoxon-Vorzeichen-Rang-Test

- die Daten sind metrisch, warum also ein nicht-parametrischer Test, z. B. weil
  - ❖ die Stichprobe klein ist
  - ❖ die Daten nicht normalverteilt sind
  - ❖ es Ausreisser gibt
- für die Teststatistik sind zuerst die paarweisen Differenzen zu berechnen

|           | Gewicht |      |      |      |      |      |      |      |      |
|-----------|---------|------|------|------|------|------|------|------|------|
| Kinder    | 1       | 2    | 3    | 4    | 5    | 6    | 7    | 8    | 9    |
| pre       | 30.0    | 35.0 | 33.0 | 28.0 | 60.0 | 37.0 | 32.0 | 29.0 | 31.0 |
| ex post   | 27.0    | 30.0 | 34.0 | 28.0 | 62.0 | 33.0 | 28.5 | 28.5 | 26.5 |
| Differenz | 3.0     | 5.0  | -1.0 | 0.0  | -2.0 | 4.0  | 3.5  | 0.5  | 4.5  |

- wir betrachten nur die Differenzen ungleich null und ordnen diese in aufsteigender Reihenfolge (das Vorzeichen wird nicht berücksichtigt)

|           |     |      |      |     |     |     |     |     |
|-----------|-----|------|------|-----|-----|-----|-----|-----|
| Differenz | 0.5 | -1.0 | -2.0 | 3.0 | 3.5 | 4.0 | 4.5 | 5.0 |
| Rang      | 1   | 2    | 3    | 4   | 5   | 6   | 7   | 8   |

# Wilcoxon-Vorzeichen-Rang-Test

---

- um die Teststatistik zu berechnen summieren wir die Ränge aller positiven und aller negativen Differenzen

$$T_+ = 1 + 4 + 5 + 6 + 7 + 8 = 31$$

$$T_- = 2 + 3 = 5$$

- zudem gibt es folgende Beziehung

$$T_+ + T_- = \frac{n(n+1)}{2}$$

mit  $n$  ist die Zahl der paarweisen Differenzen ungleich null

- die Beziehung führt zu folgender Gleichung

$$\mu_T = \frac{n(n+1)}{4}$$

- die Teststatistik ist der grössere Wert

$$w = \max(T_+; T_-)$$

- je weiter weg der Wert der Teststatistik vom durchschnittlichen Wert ist, desto eher verwerfen wir  $H_0$

# Wilcoxon-Vorzeichen-Rang-Test

- in unserem Fall haben wir die folgenden Werte

$$T_+ = 31$$

$$\mu_T = \frac{n(n+1)}{4} = \frac{8(8+1)}{4} = 18$$

– Schritt 3:

- um die Signifikanz zu berechnen betrachten wir den Mittelwert  $\mu_T$  und den Standardfehler  $SE_{\mu_T}$

$$\mu_T = \frac{n(n+1)}{4} = \frac{8(8+1)}{4} = 18$$

$$SE_{\mu_T} = \sqrt{\frac{n(n+1)(2n+1)}{24}} = \sqrt{\frac{8(8+1)(16+1)}{24}} = \sqrt{51} = 7.14$$

- mit Hilfe der Teststatistik, dem Mittelwert und dem Standardfehler können wir den  $z$  – Wert berechnen und auf Signifikanz prüfen

$$z = \frac{T - \mu_T}{SE_{\mu_T}} = \frac{31 - 18}{7.14} = 1.82$$

# Wilcoxon-Vorzeichen-Rang-Test

---

- der kritische  $z$  – Wert ist  $z_{crit} = 1.645$  (vergleiche Standardnormalverteilung)
- wir verwerfen  $H_0$
- Bemerkung:
  - tatsächlich ist die Testverteilung die Standardnormalverteilung, wenn  $n \geq 25$
  - wenn  $n < 25$  ist die Testverteilung die  $w$ -Verteilung

## Beispiel Wilcoxon-Vorzeichen-Rang-Test

---

- machen wir den Test mit dem R Commander
  - der Datensatz ist
    - schoolbreak.RData
    - der Datensatz ist simuliert
    - der Datensatz enthält das eben diskutierte Beispiel
- # lade den Datensatz "schoolbreak.Rdata"

# Beispiel Wilcoxon-Vorzeichen-Rang-Test

---

- Schritt 1:
  - Reduzieren aktive Schulpausen mit Fitnessgeräten das Gewicht von Kindern?
  - $H_0: me_{pre} - me_{post} \leq 0$
  - $H_A: me_{pre} - me_{post} > 0$
  - $\alpha = 0.05$
- Schritt 2:
  - betrachte die deskriptiven Statistiken
    - # nutze die Benutzeroberfläche des R Commanders oder die folgenden Befehle
    - attach(schoolbreak)
    - mean(pre)
    - mean(ex\_post)
    - sd(pre)
    - sd(ex\_post)
    - detach(schoolbreak)

## Beispiel Wilcoxon-Vorzeichen-Rang-Test

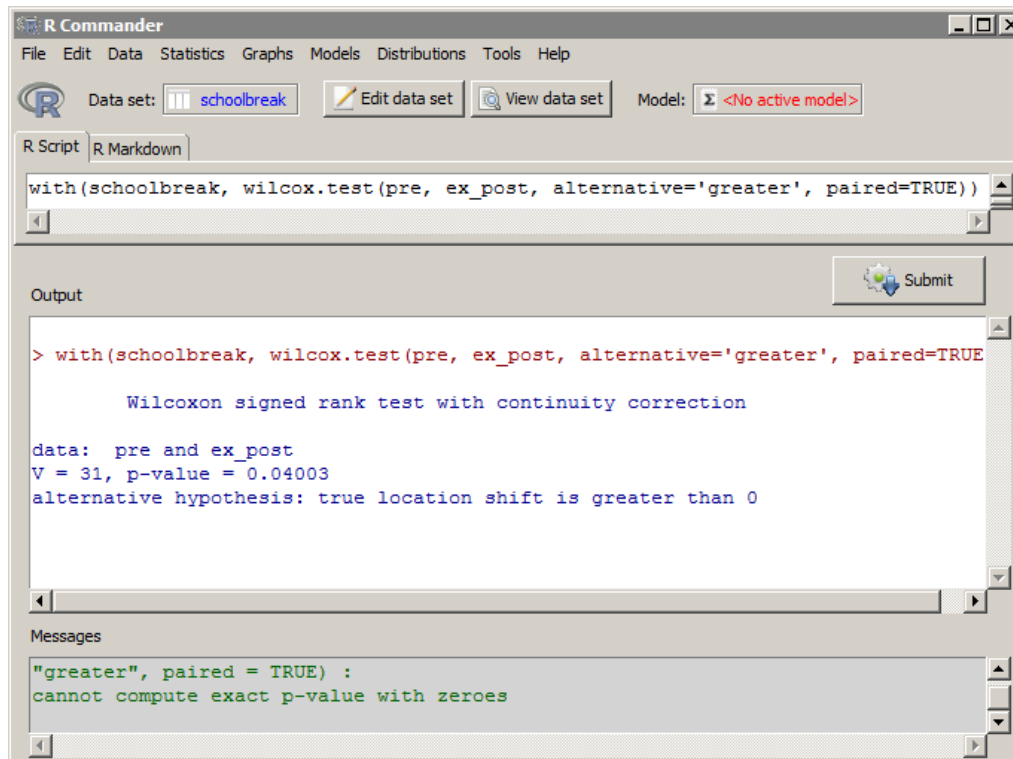
---

- prüfe auf Normalverteilung (wir lassen diesen Schritt aus, da wir aufgrund der kleinen Stichprobe und des Ausreissers entschieden haben den Wilcoxon-Vorzeichen-Rang-Test zu benutzen)
- führe den Test durch  
# nutze die Benutzeroberfläche des R Commanders oder den folgenden Befehl  
`with(schoolbreak, wilcox.test(pre, ex_post, alternative='greater', paired=TRUE))`



# Beispiel Wilcoxon-Vorzeichen-Rang-Test

## – Schritt 3:



The screenshot shows the R Commander window. The 'Data set' is 'schoolbreak'. The 'Model' is '<No active model>'. The 'R Script' tab is active, showing the command: `with(schoolbreak, wilcox.test(pre, ex_post, alternative='greater', paired=TRUE))`. The 'Output' pane shows the result: `> with(schoolbreak, wilcox.test(pre, ex_post, alternative='greater', paired=TRUE))`, followed by 'Wilcoxon signed rank test with continuity correction', 'data: pre and ex\_post', 'V = 31, p-value = 0.04003', and 'alternative hypothesis: true location shift is greater than 0'. The 'Messages' pane shows the warning: `"greater", paired = TRUE) :` and `cannot compute exact p-value with zeroes`.

```
with(schoolbreak, wilcox.test(pre, ex_post, alternative='greater', paired=TRUE))
```

```
> with(schoolbreak, wilcox.test(pre, ex_post, alternative='greater', paired=TRUE))
Wilcoxon signed rank test with continuity correction
data: pre and ex_post
V = 31, p-value = 0.04003
alternative hypothesis: true location shift is greater than 0
```

```
"greater", paired = TRUE) :
cannot compute exact p-value with zeroes
```

# Anwendungen

---

- Nutze den Datensatz `siqss.RData` (der Datensatz stammt aus dem Lehrbuch Norusis 2008). Wir sind daran interessiert, ob die Zahl der erhaltenen E-Mails (Variable `emrec`) grösser ist als die Zahl der gesendeten E-Mails (Variable `emsent`).
  - Führe den t-Test bei abhängigen Stichproben durch.
  - Führe den Wilcoxon-Vorzeichen-Rang-Test durch.
  - Vergleiche die Testergebnisse.
  - Welcher Test ist vorzuziehen? Warum?